



ESTUDO DE FAIRNESS SOBRE O DATASET DA LSAC

Relatório de Projeto de Explicabilidade e Regulamentação

Abstract

O presente trabalho analisa o impacto do enviesamento em modelos de Aprendizagem Automática aplicados à previsão do sucesso académico, recorrendo ao LSAC Bar Passage Dataset. Foram desenvolvidos e comparados modelos de Regressão Logística, Árvore de Decisão e Random Forest, avaliando o seu desempenho e a influência de atributos potencialmente sensíveis, como raça, género e rendimento familiar. A interpretabilidade dos modelos foi analisada através de técnicas intrínsecas e de métodos de Inteligência Artificial Explicável (SHAP, LIME e ELI5), permitindo identificar os fatores que influenciam as previsões globais e individuais. Por fim, é realizada uma análise ética e uma avaliação da conformidade do sistema, em cenário hipotético, com o AI Act e o RGPD.

Diogo dos Santos Silva Mendes

20251612@iade.pt

Índice

1. Introdução.....	1
2. Enquadramento do Problema.....	3
3. <i>Dataset</i> Utilizado	4
3.1. Distribuição da Variável Alvo	4
3.2. Justificação Metodológica da Seleção de <i>Features</i>	4
4. Preparação e Compreensão dos Dados	6
4.1. Seleção das Variáveis	7
4.2. Tratamento de Valores em Falta	8
4.3. Codificação das Variáveis Categóricas.....	8
4.4. Análise Exploratória dos Dados	9
4.5. Análise de Correlação	10
4.6. Separação entre Dados de Treino e Teste.....	11
4.7. Normalização das Variáveis	11
5. Desenvolvimento dos Modelos de Machine Learning	12
5.1. Regressão Logística.....	12
5.2. <i>Decision Tree</i>	13
5.3. Random Forest.....	13
5.4. Otimização dos Hiperparâmetros	14
5.4.1. Regressão Logística	15
5.4.2. <i>Decision Tree</i>	16
5.4.3. <i>Random Forest</i>	16
5.5. Avaliação dos Modelos	17
5.6. Análise Crítica dos Resultados.....	18
6. Explicabilidade dos Modelos	19
6.1. Explicabilidade Intrínseca da Regressão Logística	19
6.1.1. Interpretação dos Coeficientes	20
6.2. Interpretação da <i>Decision Tree</i>	21
6.3. Explicabilidade Global.....	22
6.3.1. Resultados com SHAP	22
6.3.2. Estudo com ELI5.....	24
6.4. Explicabilidade Local.....	26
6.4.1. Aplicação dos métodos SHAP, LIME e ELI5.....	26
6.4.1.1. Resultados com SHAP	26
6.4.1.2. Resultados com LIME.....	27
6.4.1.3. Validação das Explicações com ELI5	27
6.4.2. Comparação e discussão de Resultados	28
6.4.2.1. Caso #1 – Previsão correta (Aprovado)	28
6.4.2.2. Caso #2 – Falso Negativo.....	28
6.4.2.3. Caso #3 – Falso Negativo.....	29
6.5. Síntese dos Resultados de Explicabilidade	29
7. Análise Ética.....	31
7.1. Introdução	31
7.2. Identificação de atributos sensíveis	32

7.3.	Fairness observada nos modelos	32
7.4.	Principais riscos éticos identificados	33
7.5.	Estratégias de mitigação	34
8.	Conformidade com o AI Act.....	35
8.1.	Enquadramento	35
8.2.	Classificação do sistema segundo o AI Act.....	35
8.3.	Avaliação dos requisitos do AI Act.....	36
8.4.	Transparência e explicabilidade como requisitos regulamentares	37
8.5.	Lacunas e adaptações necessárias	37
9.	Conformidade com o GPDR	38
9.1.	Enquadramento	38
9.2.	Dados pessoais e categorias especiais	38
9.3.	Princípios do RGPD aplicáveis ao sistema	39
9.4.	Transparência e direito à explicação.....	39
9.5.	Decisões automatizadas e supervisão humana	40
9.6.	Avaliação global da conformidade	40
10.	Conclusão	42

Índice de tabelas

Tabela 1 - Conjunto final de atributos utilizados	7
Tabela 2 - Parâmetros utilizados para otimização de Regressão Linear	15
Tabela 3 - Parâmetros utilizados para otimização de Decision Tree	16
Tabela 4 - Parâmetros utilizados para otimização de Random Forest.....	17
Tabela 5 - Valores absolutos das métricas dos modelos desenvolvidos.....	18
Tabela 6 - Tabela de coeficientes e Odds Ratios da Regressão Logística	20
Tabela 7 - Pesos globais e importância de permutação atribuídos pelo ELI5	24
Tabela 8 - Amostras alvo de estudo para explicabilidade local	26
Tabela 9 - Resultados da explicabilidade local com ELI5.....	27
Tabela 10 - Análise de cumprimento dos requisitos do AI Act.....	36
Tabela 11 - Análise de cumprimento dos requisitos do GPDR	40

Índice de figuras

Figura 1 - Distribuições das variáveis binárias e categóricas.	9
Figura 2 – Distribuições das variáveis ordinais e contínuas.	9
Figura 3 - Matriz de correlação entre as variáveis utilizadas na modelação.	10
Figura 4 - Comparação das métricas globais dos modelos desenvolvidos.	17
Figura 5 - Estrutura da Decision Tree treinada.....	21
Figura 6 - Gráfico de sumário global do SHAP.....	23
Figura 7 - Resultados da explicabilidade local com SHAP.....	27
Figura 8 - Resultados da explicabilidade local com LIME.	27

1. Introdução

A crescente integração de sistemas de Inteligência Artificial (AI) em processos de decisão com impacto significativo sobre indivíduos tem levantado preocupações técnicas, éticas e jurídicas cada vez mais relevantes. Embora algoritmos de *Machine Learning* (ML) ofereçam elevada capacidade preditiva e automatização de tarefas complexas, a sua utilização em domínios sensíveis pode introduzir ou amplificar formas de discriminação difíceis de detetar sem mecanismos adequados de auditoria e explicabilidade.

Este problema torna-se particularmente crítico quando sistemas algorítmicos são utilizados em contextos relacionados com educação, recrutamento, crédito, saúde ou acesso a profissões reguladas. Nestes cenários, decisões automatizadas podem influenciar diretamente oportunidades económicas, mobilidade social e direitos fundamentais. Consequentemente, a avaliação destes sistemas não pode limitar-se à análise de métricas tradicionais de desempenho, como *accuracy* ou F1-score. Torna-se igualmente necessário compreender de que forma as previsões são produzidas, quais atributos influenciam as decisões e até que ponto fatores sensíveis podem introduzir enviesamentos sistemáticos.

Nos últimos anos, a comunidade científica tem demonstrado que modelos treinados sobre dados históricos podem reproduzir desigualdades pré-existentes na sociedade. Mesmo quando atributos explicitamente sensíveis são removidos, outras variáveis podem atuar como *proxies* de características protegidas, perpetuando padrões discriminatórios de forma menos visível. Este fenómeno, geralmente designado por *algorithmic bias*, representa um dos principais desafios contemporâneos da AI responsável.

No contexto da unidade curricular de Explicabilidade e Regulamentação, o presente projeto foi desenvolvido com foco específico na análise de bias algorítmico em modelos supervisionados. Assim, o objetivo central deste trabalho não consistiu exclusivamente em maximizar capacidade preditiva, mas também construir e analisar modelos suficientemente robustos para permitir estudar, explicar e discutir mecanismos de enviesamento presentes nos dados e nas previsões.

Para esse efeito foi utilizado o dataset *Law School Admissions Bar Passage*¹, amplamente conhecido na literatura por ser um caso de estudo relevante em *fairness* e explicabilidade.²

Este *dataset* contém informação académica, socioeconómica e demográfica relativa aos participantes do exame (bar) para poderem exercer Direito. Ele foi disponibilizado pela *Law School Admissions Council* (LSAC, entidade criadora e aplicadora do *Law School Admission Test* (LSAT), um teste global, necessário para admissão em faculdades de direito nos USA e Canadá).

¹ <https://www.kaggle.com/danofer/law-school-admissions-bar-passage>

² LSAC National Longitudinal Bar Passage Study. LSAC Research Report Series.

<https://archive.lawschooltransparency.com/reform/projects/investigations/2015/documents/NLBPS.pdf>

A escolha deste *dataset* revelou-se particularmente adequada por três razões:

1. Trata-se de um problema de decisão de elevado impacto, uma vez que a aprovação no exame determina o acesso à profissão jurídica.
2. O *dataset* inclui atributos sensíveis, como raça, género e rendimento familiar, permitindo observar diretamente potenciais padrões de discriminação algorítmica.
3. A existência simultânea de variáveis académicas e variáveis socioeconómicas que permite estudar a interação entre mérito observável e desigualdade estrutural.

Este último aspeto constitui o eixo conceptual central do presente trabalho. Em particular, pretende-se analisar até que ponto atributos sensíveis conseguem influenciar previsões algorítmicas mesmo quando o modelo dispõe de indicadores objetivos de mérito académico. Dito de outra forma, procurou-se responder à seguinte questão:

Pode um modelo de AI reproduzir bias demográfico mesmo na presença de sinais fortes de mérito individual?

Responder a esta questão exige uma abordagem multidimensional. Assim, o trabalho combina modelação supervisionada, técnicas de *Explainable Artificial Intelligence* (XAI), análise crítica de *fairness* e reflexão regulamentar, permitindo avaliar não apenas o desempenho dos modelos, mas também a legitimidade e o risco da sua utilização em cenários reais.

De forma mais concreta, o projeto procura atingir os seguintes objetivos:

- Análise exploratória detalhada do conjunto de dados, identificando características estatísticas relevantes, distribuições das variáveis e potenciais limitações do *dataset*.
- Treinar e comparar diferentes algoritmos supervisionados, incluindo modelos intrinsecamente interpretáveis e modelos *black-box*, de modo a observar como arquiteturas distintas capturam padrões presentes nos dados.
- Aplicar métodos modernos de XAI para compreender tanto o comportamento global dos modelos como previsões individuais. Esta análise permitirá identificar quais variáveis exercem maior influência sobre as decisões e em que contextos essa influência se manifesta.
- Enquadrar os resultados obtidos com princípios éticos e regulamentares, discutindo os riscos associados à utilização prática de sistemas desta natureza em contextos de alto impacto.

Nota: Todo o código desenvolvido, logs de execução, figuras geradas e o dataset usado podem ser consultados em https://github.com/diogosantosmendes/executivemaster_xai

2. Enquadramento do Problema

O problema abordado neste trabalho pode ser formalizado como um problema de classificação supervisionada binária. Dado um conjunto de atributos descritivos de um candidato, pretende-se prever se este será aprovado ou reprovado no exame da Ordem dos Advogados.

Formalmente, procura-se aprender uma função: $f(x) \rightarrow y$ onde x representa o vetor de características do candidato e y corresponde à variável alvo.

Embora esta formulação seja relativamente simples do ponto de vista matemático, o contexto de aplicação introduz complexidades adicionais. Em particular, as decisões associadas a aprovação ou reprovação têm consequências diretas no acesso a oportunidades profissionais e rendimento futuro.

Assim, erros de classificação não têm impacto homogéneo. Um falso negativo — prever reprovação para um candidato que seria aprovado — pode traduzir-se em perda injustificada de oportunidade profissional. Da mesma forma, padrões sistemáticos de erro concentrados em grupos específicos podem configurar discriminação algorítmica.

Este facto torna insuficiente uma análise baseada exclusivamente em métricas agregadas. Um modelo com elevada *accuracy* pode continuar a ser problemático caso produza decisões desproporcionalmente desfavoráveis para determinados grupos demográficos.

Por essa razão, neste trabalho o desempenho preditivo é interpretado como apenas uma das dimensões relevantes de avaliação, coexistindo com critérios de explicabilidade, *fairness* e conformidade regulatória.

3. *Dataset* Utilizado

Como já referido, foi utilizado o *dataset Law School Admissions Bar Passage*, frequentemente utilizado em investigação sobre *fairness* em AI aplicado a contextos educacionais e profissionais.

O *dataset* da LSAC contém observações relativas a candidatos ao exame (bar), incluindo informação académica, demográfica e socioeconómica. Estas características tornam-no particularmente adequado para estudar fenómenos de bias algorítmico, uma vez que combina atributos associados a mérito individual com atributos potencialmente sensíveis.

Após limpeza e preparação inicial, o conjunto de dados utilizado apresenta aproximadamente 22 mil observações válidas, constituindo uma amostra suficientemente grande para treino e avaliação de modelos supervisionados.

A variável alvo do problema é `PASS_BAR`, que representa a aprovação no exame.

3.1. Distribuição da Variável Alvo

Uma análise inicial revelou um forte desbalanceamento entre classes. A larga maioria dos candidatos presentes no *dataset* obteve aprovação no exame.

A distribuição observada foi aproximadamente:

- 94.85% aprovados
- 5.15% reprovados

Este desequilíbrio possui implicações metodológicas importantes. Em particular, métricas como *accuracy* tornam-se insuficientes para avaliar adequadamente o desempenho dos modelos, uma vez que classificadores enviesados para a classe maioritária podem aparentar bom desempenho global.

Consequentemente, o projeto utiliza métricas complementares como *precision*, *recall* e *F1-score*, bem como técnicas de balanceamento por *weighting* durante o treino.

3.2. Justificação Metodológica da Seleção de *Features*

Uma das decisões metodológicas mais importantes deste projeto diz respeito à seleção das variáveis utilizadas na modelação.

Ao contrário de abordagens tradicionais de *Machine Learning*, nas quais a seleção de *features* é orientada principalmente pela maximização de capacidade preditiva, neste trabalho a escolha das variáveis foi deliberadamente condicionada pelo objetivo de estudar bias algorítmico.

O enunciado da unidade curricular recomendava a utilização de *datasets* já conhecidos por apresentarem potenciais problemas de *fairness*, precisamente para

facilitar a análise crítica de mecanismos de discriminação algorítmica. Neste contexto, a seleção de atributos procurou preservar simultaneamente variáveis representativas de mérito acadêmico e variáveis associadas a desigualdade estrutural.

Entre os atributos acadêmicos foi mantida a variável *UGPA* (*Undergraduate Grade Point Average*), utilizada como indicador de desempenho acadêmico anterior aos estudos universitários. A inclusão desta *feature* teve uma importância conceptual central, pois permitiu incorporar no modelo um fator que, em princípio, representa mérito individual de forma objetiva.

A escolha de manter *UGPA* foi também motivada pela intenção de simular um cenário de previsão antecipada de sucesso profissional. Conceptualmente, pretendeu-se aproximar uma situação em que se procura estimar o potencial sucesso futuro de um jovem candidato numa fase relativamente precoce do seu percurso académico, antes de completar toda a formação ou avaliação profissional.

Em contraste, a variável *LSAT*, tradicionalmente uma das *features* mais preditivas neste *dataset*, foi excluída deliberadamente. Embora a sua inclusão provavelmente aumentasse a performance global dos modelos, também reduziria significativamente a visibilidade do impacto relativo de variáveis socioeconómicas e demográficas.

A exclusão de *LSAT* teve, portanto, um propósito metodológico claro: evitar que uma variável extremamente dominante mascarasse potenciais mecanismos de bias.

Paralelamente, foram mantidos atributos sensíveis ou estruturalmente relevantes, nomeadamente:

- raça;
- género;
- rendimento familiar.

Esta configuração experimental permitiu estudar a interação entre mérito e bias. Em particular, tornou-se possível analisar situações em que fatores demográficos exercem influência suficiente para contrariar sinais académicos positivos.

Este fenómeno revelou-se central nos resultados obtidos. Embora *UGPA* surja consistentemente como a variável de maior importância global, observaram-se casos em que variáveis raciais — particularmente *RACE_BLACK* — apresentaram influência suficiente para alterar significativamente previsões individuais.

Tal resultado constitui uma evidência importante de que a presença de indicadores meritocráticos robustos não elimina, por si só, o risco de enviesamento algorítmico.

4. Preparação e Compreensão dos Dados

Antes do desenvolvimento dos modelos preditivos, foi realizada uma fase de preparação dos dados destinada a garantir a qualidade da informação utilizada durante o processo de aprendizagem. Esta etapa é particularmente importante em projetos de *Machine Learning*, uma vez que a qualidade das previsões depende diretamente da qualidade dos dados disponibilizados ao modelo.

No contexto deste trabalho, esta fase assumiu ainda uma importância adicional. Como o objetivo principal consiste na análise de enviesamento algorítmico, tornou-se essencial garantir que a preparação dos dados não introduzisse transformações que eliminassem ou mascarassem os padrões de bias existentes no *dataset* original.

Todas as operações realizadas procuraram preservar as relações estatísticas presentes nos dados, assegurando simultaneamente a compatibilidade com os algoritmos utilizados.

O pipeline de preparação implementado pode ser resumido pelas seguintes etapas:

1. carregamento do dataset;
2. seleção das variáveis de interesse;
3. tratamento de valores em falta;
4. codificação de variáveis categóricas;
5. separação entre treino e teste;
6. normalização seletiva para a Regressão Logística.

O excerto seguinte apresenta todo o processo de carregamento e transformação dos dados, que será abordado nos próximos capítulos.

```
df = pd.read_csv('data/bar_pass_prediction.csv')

# Select columns to be used
columns_of_interest = ['race1', 'male', 'fam_inc', 'tier', 'ugpa', 'pass_bar']
# Drop rows with null or empty values from columns of interest
df = df[columns_of_interest].dropna()

clean_df = df[['ugpa', 'pass_bar']]
clean_df["race"] = df["race1"] # rename 'race1' to 'race' -> improve readability of categoric features
clean_df["male"] = df["male"].astype(int)
clean_df["fam_inc"] = df["fam_inc"].astype(int)
clean_df["tier"] = df["tier"].astype(int)

# One-Hot encoding on categoric features ('race')
df_encoded = pd.get_dummies(clean_df, columns=['race'], drop_first=False, dtype=int)
# drop race_white column as only adds noise
df_encoded = df_encoded.drop(columns=["race_white"])
```

4.1. Seleção das Variáveis

Embora o *dataset* LSAC disponibilize um número significativamente superior de atributos, nem todas as variáveis foram utilizadas durante a modelação.

Esta decisão não foi motivada apenas por critérios de redução de dimensionalidade, mas sobretudo pela finalidade do projeto.

Conforme referido anteriormente, pretendeu-se estudar a interação entre indicadores de mérito académico e atributos potencialmente associados a desigualdades estruturais. Assim, foram selecionadas apenas as variáveis consideradas mais relevantes para essa análise.

Variável	Tipo	Intervalo de valores	Papel na análise
UGPA	Numérica	[0-5]	Indicador de mérito académico
TIER	Ordinal	[1,2,3,4,5]	Prestígio institucional
FAM_INC	Ordinal	[1,2,3,4,5]	Contexto socioeconómico
RACE	Categórica	asian, black, hisp, other, white	Atributo sensível
MALE	Binária	1 (verdadeiro) 0 (falso)	Atributo sensível
PASS_BAR	Binária	1 (verdadeiro) 0 (falso)	Variável alvo

Tabela 1 - Conjunto final de atributos utilizados

Tal como discutido na secção anterior, a exclusão da variável *LSAT* constituiu uma decisão metodológica deliberada. Sendo uma das variáveis mais fortemente correlacionadas com o resultado final (*PASS_BAR*) e com o indicador de mérito académico (*UGPA*), a sua inclusão poderia reduzir significativamente a influência relativa dos restantes atributos, dificultando a observação dos mecanismos de bias que constituem o principal objeto de estudo deste trabalho.

Em contrapartida, a manutenção de *UGPA* permitiu preservar um indicador de desempenho académico considerado representativo do mérito individual, possibilitando analisar em que medida fatores demográficos podem influenciar previsões mesmo na presença de um forte sinal académico.

4.2. Tratamento de Valores em Falta

Após a seleção das variáveis, procedeu-se à verificação da existência de valores omissos em falta que pudessem comprometer o processo de aprendizagem dos modelos, conduzindo a erros de execução ou à degradação do desempenho preditivo.

No presente *dataset*, optou-se por remover essas observações em vez de recorrer a técnicas de imputação por duas razões:

1. A quantidade de registos removidos representa uma fração muito reduzida do conjunto total de dados, não comprometendo a representatividade estatística da amostra.
2. Técnicas de imputação poderiam introduzir relações artificiais entre variáveis, interferindo na análise de *fairness* que constitui um dos objetivos centrais deste estudo.

4.3. Codificação das Variáveis Categóricas

Os algoritmos de *ML* utilizados neste projeto requerem que todas as variáveis sejam representadas numericamente.

Enquanto variáveis contínuas como *UGPA* ou *TIER* já se encontravam em formato numérico, a variável *RACE* correspondia a uma categoria nominal composta por diferentes grupos raciais.

Para preservar toda a informação sem introduzir relações ordinais artificiais entre categorias, foi utilizada codificação *One-Hot Encoding*.

Esta abordagem cria uma variável binária para cada categoria racial, permitindo que cada grupo seja tratado de forma independente pelo modelo.

A opção `DROP_FIRST=TRUE` elimina uma das categorias, que passa a funcionar como categoria de referência. Mas neste caso, foi definido a `FALSE` e manualmente descartada a categoria `WHITE`, pois é a categoria dominante no *dataset* e evita-se a *dummy variable trap*, isto é, uma situação de colinearidade perfeita entre variáveis, particularmente problemática em modelos lineares como a Regressão Logística.

No contexto deste trabalho, esta escolha possui ainda uma vantagem adicional. Os coeficientes estimados para cada variável racial passam a representar diretamente a diferença relativamente ao grupo de referência, facilitando posteriormente a interpretação dos resultados obtidos através da Regressão Logística.

4.4. Análise Exploratória dos Dados

Antes da construção dos modelos foi realizada uma análise exploratória destinada a compreender melhor a distribuição das variáveis e identificar relações potencialmente relevantes.

Foram produzidas diversas visualizações recorrendo à biblioteca Matplotlib, permitindo observar distribuições individuais, frequências das categorias e relações entre atributos.

Embora esta etapa seja comum em qualquer projeto de Ciência de Dados, neste trabalho assume especial importância por permitir identificar indícios preliminares de potenciais desigualdades presentes no *dataset*.

Em particular, procurou-se verificar:

- distribuição das categorias raciais;
- distribuição do rendimento familiar (FAM_INC);
- equilíbrio entre géneros;
- distribuição do desempenho académico (UGPA);
- distribuição do ranking de instituições de ensino (TIER);
- distribuição da variável alvo (PASS_BAR).




Figura 1 - Distribuições das variáveis binárias e categóricas.




Figura 2 – Distribuições das variáveis ordinais e contínuas.

Estas observações permitiram confirmar o forte desbalanceamento entre classes, bem como diferenças de representação entre dos grupos demográficos, sendo considerável a dominância de registos da raça branca.

4.5. Análise de Correlação

Foi igualmente calculada a matriz de correlação entre as variáveis numéricas e binárias resultantes da codificação.

A matriz de correlação permite identificar relações lineares entre variáveis e constitui uma ferramenta útil para detetar potenciais problemas de multicolinearidade.

Para o presente estudo, esta análise teve sobretudo um carácter exploratório. Não se pretendeu eliminar variáveis altamente correlacionadas, uma vez que o objetivo consistia em preservar os mecanismos presentes nos dados para posterior análise de bias.

Ainda assim, verificou-se que a *TIER*, a *UGPA* e a *FAM_INC* apresentam as correlações positivas mais fortes com a variável alvo, resultado coerente com a expectativa de que o desempenho académico seja um dos principais determinantes da aprovação no exame e que melhores situações socioeconómicas (*FAM_INC* alto) permitem o estudo em instituições com melhor qualidade de ensino (*TIER* alto).

A correlação linear mais evidente foi entre a *UGPA* e a *TIER*, o que é expectável, pois melhores avaliações académicas permitem acesso a faculdades com maior *ranking*.




Figura 3 - Matriz de correlação entre as variáveis utilizadas na modelação.

Em contraste, as variáveis demográficas apresentam correlações mais reduzidas quando analisadas individualmente. No entanto, tal não implica ausência de influência. Como será demonstrado nas secções dedicadas à interpretabilidade, modelos não lineares conseguem explorar interações complexas entre múltiplas variáveis, atribuindo importância significativa a alguns atributos sensíveis apesar da sua reduzida correlação linear.

4.6. Separação entre Dados de Treino e Teste

Após a preparação dos dados, procedeu-se à separação entre os conjuntos de treino e teste.

Foi utilizada uma divisão de 90% para treino e 10% para teste, garantindo um número elevado de observações disponíveis para aprendizagem, sem comprometer a existência de um conjunto independente para avaliação final.

A utilização do parâmetro `STRATIFY=Y` revelou-se particularmente importante devido ao forte desbalanceamento existente entre aprovados e reprovados. Esta opção assegura que ambas as partições mantêm aproximadamente a mesma proporção de classes observada no *dataset* original, evitando que diferenças acidentais na distribuição comprometam a comparação entre modelos.

```
X = df_encoded.drop(columns=['pass_bar'])
y = df_encoded['pass_bar']

# Splitting the data (90% training, 10% testing)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.1, random_state=42, stratify=y)
```

4.7. Normalização das Variáveis

Embora todos os modelos utilizem o mesmo conjunto de atributos, apenas a Regressão Logística foi treinada sobre dados normalizados.

```
# Feature scaling using StandardScaler
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Esta decisão foi tomada por razões relacionadas com o funcionamento interno dos algoritmos. A Regressão Logística estima os seus parâmetros através de métodos de otimização iterativos, sendo sensível à escala das variáveis. Quando diferentes atributos apresentam amplitudes muito distintas, o processo de otimização pode convergir mais lentamente ou atribuir pesos difíceis de interpretar.

A normalização através do *StandardScaler* transforma cada variável contínua para uma distribuição com média aproximadamente igual a zero e desvio padrão unitário, tornando os coeficientes diretamente comparáveis entre si.

Em contraste, modelos baseados em árvores de decisão, como *Decision Tree* e *Random Forest*, efetuam divisões recorrendo apenas à ordem relativa dos valores e aos limiares de separação, sendo agnósticos à escala das *features*. Assim, a aplicação de normalização nestes modelos não produziria benefícios significativos, podendo mesmo dificultar a interpretação intuitiva dos pontos de divisão.

A opção por aplicar *feature scaling* apenas à Regressão Logística permitiu simultaneamente manter a consistência metodológica e melhorar a interpretação dos coeficientes estimados, sem comprometer o desempenho preditivo observado.

5. Desenvolvimento dos Modelos de Machine Learning

Concluída a preparação dos dados, procedeu-se ao desenvolvimento dos modelos supervisionados. A seleção dos algoritmos não foi orientada apenas pelo seu desempenho preditivo, mas sobretudo pela possibilidade de comparar diferentes níveis de interpretabilidade e diferentes mecanismos de aprendizagem.

Para esse efeito foram escolhidos três modelos representativos de abordagens distintas: Regressão Logística, *Decision Tree* e *Random Forest*.

Todos estes modelos foram implementados com recurso à biblioteca [Scikit-learn](#).

A Regressão Logística representa um modelo linear intrinsecamente interpretável, permitindo analisar diretamente o impacto de cada variável através dos coeficientes estimados.

A *Decision Tree* constitui igualmente um modelo interpretável, mas capaz de capturar relações não lineares através de sucessivas divisões do espaço de atributos.

Finalmente, a *Random Forest* representa um modelo ensemble significativamente mais complexo, utilizado como representante de modelos *black-box*, cuja capacidade preditiva é normalmente superior à custa de uma redução da transparência.

Esta combinação permite analisar um aspeto central deste trabalho: compreender de que forma diferentes arquiteturas aprendem os mesmos dados e se convergem para padrões semelhantes de influência das variáveis.

5.1. Regressão Logística

A Regressão Logística constitui um dos modelos mais utilizados em problemas de classificação binária devido à sua simplicidade, robustez e elevada interpretabilidade.

Ao contrário da regressão linear tradicional, este algoritmo não estima diretamente a variável alvo. Em vez disso, modela a probabilidade de ocorrência da classe positiva através da função logística (sigmoide), garantindo que todas as previsões permaneçam no intervalo $[0, 1]$.

A relação entre as variáveis independentes e a probabilidade prevista pode ser expressa por: $P(Y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$ onde β_i representa o coeficiente associado a cada variável.

Uma das principais vantagens deste modelo reside precisamente na interpretação dos coeficientes estimados. Cada coeficiente representa a variação do logaritmo das *odds* de aprovação associada a uma unidade de variação da respetiva variável, mantendo as restantes constantes.

Como referido no capítulo 4.7, este foi o único modelo treinado sobre dados normalizados através do *StandardScaler*, permitindo comparar diretamente a magnitude dos coeficientes associados às variáveis contínuas.

Ao invés de fixar previamente determinados hiperparâmetros, optou-se por integrar a Regressão Logística num processo de otimização por *Grid Search*, permitindo selecionar automaticamente a configuração com melhor capacidade de generalização. Foram avaliadas diferentes combinações para o número máximo de iterações (*max_iter*) e para a utilização de ponderação das classes (*class_weight*).

5.2. Decision Tree

A *Decision Tree* constitui um modelo supervisionado baseado em sucessivas divisões do espaço de atributos. Cada nó interno representa uma decisão sobre uma determinada variável, enquanto cada folha corresponde à classe prevista.

Ao contrário da Regressão Logística, este algoritmo não assume relações lineares entre variáveis, sendo capaz de representar interações complexas através de regras hierárquicas.

O processo de construção da árvore consiste na seleção iterativa das divisões dos dados.

A principal vantagem desta abordagem reside na sua elevada interpretabilidade. Uma vez treinada, a árvore pode ser percorrida desde a raiz até às folhas, permitindo compreender exatamente quais as condições responsáveis por cada previsão.

5.3. Random Forest

Embora uma *Decision Tree* individual seja facilmente interpretável, pequenas alterações nos dados de treino podem originar árvores significativamente diferentes.

A *Random Forest* procura reduzir esta instabilidade através da combinação de múltiplas árvores treinadas de forma independente.

Cada árvore é construída recorrendo simultaneamente a:

- amostras aleatórias do conjunto de treino (*Bootstrap Sampling*);
- subconjuntos aleatórios de variáveis (*Feature Bagging*).

A previsão final resulta da agregação das previsões individuais através de votação maioritária.

Este mecanismo reduz significativamente a variância do modelo, aumentando a capacidade de generalização.

No contexto deste trabalho, a *Random Forest* desempenha um papel particularmente importante por representar um modelo de elevada capacidade preditiva, mas intrinsecamente difícil de interpretar sem recurso a técnicas adicionais de *Explainable*

AI, sendo um excelente candidato para aplicação posterior de métodos como SHAP, LIME e ELI5.

5.4. Otimização dos Hiperparâmetros

Após a definição dos modelos base, procedeu-se à otimização dos respetivos hiperparâmetros utilizando *Grid Search* com validação cruzada de cinco partições (*5-Fold Cross Validation*).

A utilização de *Grid Search* permite explorar sistematicamente diferentes combinações de parâmetros, selecionando aquela que produz melhor desempenho médio durante a validação cruzada.

```
models = {
    "Logistic Regression": [
        LogisticRegression(random_state=42),      # algorithm
        True,                                     # use scaled values
        {                                          # params
            'max_iter': [500, 1000, 2000],
            'class_weight': ['balanced', None]
        }
    ],
    "Decision Tree": [
        DecisionTreeClassifier(random_state=42),   # algorithm
        False,                                    # use scaled values
        {                                          # params
            'max_depth': [10, 30, 50, 100, None],
            'min_samples_split': [2, 5, 10, 20],
            'min_samples_leaf': [1, 2, 5, 10],
            'criterion': ['gini', 'entropy'],
            'class_weight': ['balanced', None]
        }
    ],
    "Random Forest": [
        RandomForestClassifier(random_state=42),   # algorithm
        False,                                    # use scaled values
        {                                          # params
            'n_estimators': [50, 100],
            'max_depth': [None, 10, 20],
            'min_samples_split': [2, 5],
            'class_weight': ['balanced', 'balanced_subsample', None]
        }
    ],
}

specificity_scorer = make_scorer(recall_score, pos_label=0)

for name, (model, use_scaled, param_grid) in models.items():
    X_train_to_use, X_test_to_use = (X_train_scaled, X_test_scaled) if use_scaled else (X_train, X_test)

    # Train the model
    print(f"\n--- Hyperparameter Tuning (Grid Search) on {name} ---")

    grid_search = GridSearchCV(
        estimator=model,
        param_grid=param_grid,
        cv=5,
        scoring=specificity_scorer,
        n_jobs=-1,
        verbose=2
    )
    grid_search.fit(X_train_to_use, y_train)

    print(f"Best Parameters: {grid_search.best_params_}")

    # Assign best estimated model
    model = grid_search.best_estimator_
    models[name][0] = model
```

Ao contrário da abordagem tradicional, que normalmente utiliza métricas como *accuracy* ou *F1-score* para selecionar os melhores hiperparâmetros, neste trabalho foi definida uma métrica personalizada baseada na *specificity*.

Embora esta métrica seja implementada através da função *recall_score*, ao definir *pos_label=0*, o processo de otimização passa a maximizar especificamente a capacidade do modelo identificar corretamente os candidatos pertencentes à classe minoritária, ou seja, os candidatos reprovados. Apesar da variável no código ser designada *specificity_scorer*, a métrica otimizada corresponde, do ponto de vista matemático, ao *recall* da classe minoritária.

Esta decisão foi deliberada e encontra-se diretamente relacionada com os objetivos do projeto. Dado que aproximadamente 95% das observações pertencem à classe dos candidatos aprovados, uma otimização baseada apenas na *accuracy* conduziria naturalmente a modelos excessivamente orientados para a classe majoritária. Mesmo métricas mais equilibradas, como o *F1-score*, continuariam a ser fortemente influenciadas pelo elevado número de candidatos aprovados.

Ao privilegiar a capacidade de identificar corretamente os candidatos reprovados durante o processo de seleção de hiperparâmetros, procurou-se reduzir este efeito, incentivando os modelos a prestar maior atenção à classe minoritária. Esta estratégia é particularmente relevante num estudo centrado na análise de bias algorítmico, uma vez que permite observar com maior detalhe o comportamento dos modelos nos casos mais difíceis de classificar.

Outra estratégia implementada que procurou compensar o forte desbalanceamento existente entre candidatos aprovados e reprovados foi a utilização do parâmetro *class_weight="BALANCED"*, nos 3 algoritmos estudados, atribuindo maior peso à classe minoritária durante a otimização da função de custo. Sem esta configuração, o modelo tenderia a privilegiar excessivamente a classe majoritária, reduzindo a capacidade de identificar candidatos reprovados.

Cada algoritmo foi posteriormente otimizado recorrendo a um conjunto de hiperparâmetros específicos, adequado às suas características.

5.4.1. Regressão Logística

Na Regressão Logística foram exploradas diferentes configurações para o número máximo de iterações (*max_iter*) e para a utilização de ponderação automática das classes (*class_weight*).

Tabela 2 - Parâmetros utilizados para otimização de Regressão Linear

Parâmetro	Valores testados	Justificação
<i>max_iter</i>	500, 1000, 2000	Garantir convergência do algoritmo em diferentes cenários de otimização.
<i>class_weight</i>	NONE, BALANCED	Avaliar o impacto do balanceamento automático das classes num dataset fortemente desbalanceado.

O Grid Search selecionou como configuração ótima:

- `class_weight` = **BALANCED**
- `max_iter` = **500**

5.4.2. Decision Tree

Na *Decision Tree* foram otimizados os parâmetros responsáveis pela complexidade estrutural da árvore. Foram avaliadas diferentes profundidades máximas (`max_depth`), números mínimos de amostras necessários para dividir um nó (`min_samples_split`) e para constituir uma folha (`min_samples_leaf`), bem como os critérios de *split* dos dados em cada nó: **GINI** e **ENTROPY**.

Tabela 3 - Parâmetros utilizados para otimização de *Decision Tree*

Parâmetro	Valores testados	Justificação
<code>max_depth</code>	10, 30, 50, 100 , NONE	A profundidade limitada da árvore e o número mínimo de observações por folha contribuem para reduzir o risco de sobreajuste, favorecendo simultaneamente uma estrutura mais estável e interpretável.
<code>min_samples_split</code>	2, 5, 10, 20	
<code>min_samples_leaf</code>	1, 2, 5, 10	
<code>criterion</code>	GINI, ENTROPY	Testar se a árvore beneficiava mais do cálculo rápido do Gini ou das divisões mais equilibradas geradas pela Entropia.
<code>class_weight</code>	NONE, BALANCED	Avaliar o impacto do balanceamento automático das classes num <i>dataset</i> fortemente desbalanceado.

O Grid Search selecionou como configuração ótima:

- `criterion` = **'GINI'**
- `max_depth` = **10**
- `min_samples_leaf` = **10**
- `min_samples_split` = **2**
- `class_weight` = **'BALANCED'**

5.4.3. Random Forest

Na *Random Forest* foram avaliados hiperparâmetros relacionados com a dimensão do ensemble e com a complexidade individual das árvores.

Tabela 4 - Parâmetros utilizados para otimização de Random Forest

Parâmetro	Valores testados	Justificação
<i>n_estimators</i>	50, 100	Ajuste da complexidade do modelo, evitando árvores excessivamente profundas e reduzindo o risco de sobreajuste
<i>max_depth</i>	10, 20, NONE	
<i>min_samples_split</i>	2, 5	Avaliar o impacto do balanceamento automático das classes num <i>dataset</i> fortemente desbalanceado.
<i>class_weight</i>	NONE, BALANCED, BALANCED_SUBSAMPLE	

O *Grid Search* selecionou como configuração ótima:

- *n_estimators* = **100**
- *max_depth* = **10**
- *min_samples_split* = **5**
- *class_weight* = **'BALANCED'**

5.5. Avaliação dos Modelos

Concluído o processo de otimização dos hiperparâmetros, cada modelo foi treinado utilizando a configuração considerada ótima pelo *Grid Search* e posteriormente avaliado sobre o conjunto de teste, que permaneceu completamente independente durante todo o processo de desenvolvimento.

A avaliação foi efetuada recorrendo às métricas habitualmente utilizadas em problemas de classificação binária: *Accuracy*, *Precision*, *Recall* e *F1-score*. Atendendo ao elevado desbalanceamento existente entre candidatos aprovados e reprovados, a interpretação destas métricas exige alguma cautela.




Figura 4 - Comparação das métricas globais dos modelos desenvolvidos.

Tabela 5 - Valores absolutos das métricas dos modelos desenvolvidos

	GLOBAL	WEIGHTED AVG			CLASSE - 0			CLASSE - 1		
	Accuracy	Precision	Recall	F1-Score	Precision	Recall	F1-Score	Precision	Recall	F1-Score
LOGISTIC REGRESSION	0,7489	0,9341	0,7489	0,818	0,1296	0,6814	0,2178	0,9776	0,7525	0,8504
DECISION TREE	0,7761	0,9289	0,7761	0,8358	0,1289	0,5841	0,2112	0,9722	0,7865	0,8695
RANDOM FOREST	0,7965	0,9243	0,7965	0,8484	0,1253	0,4956	0,2000	0,9675	0,8128	0,8835

Observa-se uma evolução consistente do desempenho à medida que aumenta a complexidade dos modelos. A Regressão Logística apresenta o desempenho global mais modesto, seguida pela *Decision Tree*, enquanto a *Random Forest* obtém os melhores resultados nas métricas globais consideradas.

5.6. Análise Crítica dos Resultados

A análise conjunta das métricas evidencia uma tendência particularmente relevante. Embora os modelos de maior complexidade apresentem melhorias consistentes nas métricas globais de desempenho, essa evolução não ocorre de forma uniforme entre as duas classes do problema.

Observa-se que todas as métricas associadas à classe majoritária (classe 1) melhoram progressivamente da Regressão Logística para a *Random Forest*. Em sentido inverso, todas as métricas relativas à classe minoritária apresentam uma degradação gradual. O *recall* da classe 0 diminui de 68,14% para 49,56%, sendo igualmente acompanhada por reduções na *precision* e no *F1-score*.

Estes resultados sugerem que o aumento da capacidade de generalização dos modelos é obtido principalmente através de uma aprendizagem mais eficaz dos padrões estatísticos dominantes no conjunto de dados. Como a classe dos candidatos aprovados representa a larga maioria das observações (95%, com 2089 registros), os algoritmos mais complexos tendem naturalmente a privilegiar essa classe, conduzindo a melhorias significativas nas métricas globais, mas reduzindo simultaneamente a sensibilidade relativamente aos candidatos reprovados.

Esta observação assume especial importância no contexto do presente trabalho. O objetivo do projeto não consiste apenas em maximizar a capacidade preditiva, mas compreender de que forma diferentes modelos distribuem o seu desempenho entre grupos distintos de observações. Os resultados demonstram que um aumento da *accuracy* não implica necessariamente um comportamento mais equilibrado ou mais justo, reforçando a necessidade de complementar a avaliação quantitativa com métodos de *Explainable AI* que permitam compreender quais os atributos responsáveis pelas decisões produzidas pelos modelos.

6. Explicabilidade dos Modelos

Após a avaliação quantitativa dos modelos, procedeu-se à análise do seu comportamento interno recorrendo a diferentes técnicas de *Explainable Artificial Intelligence* (XAI). Enquanto as métricas apresentadas no capítulo anterior permitem avaliar a qualidade das previsões, não fornecem informação acerca dos fatores responsáveis pelas decisões produzidas pelos modelos.

Num contexto como o presente, onde o objetivo consiste em estudar potenciais mecanismos de enviesamento algorítmico, esta limitação assume particular relevância. Saber que um modelo apresenta elevada *accuracy* é insuficiente para concluir que as suas decisões são justas, transparentes ou adequadas para utilização em contextos de elevado impacto.

Assim, foram aplicadas técnicas de explicabilidade tanto a nível global como local, permitindo responder a duas questões complementares.

1. Identificar quais as variáveis que exercem maior influência sobre o comportamento global dos modelos.
2. Compreender a razão de um determinado candidato ser classificado como aprovado ou reprovado.

A utilização conjunta de diferentes métodos permite obter uma visão mais completa do processo de decisão, uma vez que cada técnica apresenta vantagens e limitações próprias.

6.1. Explicabilidade Intrínseca da Regressão Logística

Entre os três algoritmos desenvolvidos, a Regressão Logística constitui o modelo mais facilmente interpretável.

Ao contrário dos modelos baseados em árvores ou ensembles, os coeficientes estimados possuem significado estatístico direto, permitindo quantificar o impacto individual de cada variável sobre a probabilidade prevista.

Após o treino do modelo, foram extraídos os coeficientes correspondentes a cada atributo, bem como os respetivos *Odds Ratios*, obtidos através da exponenciação dos coeficientes. Assim é possível expressar o efeito de cada variável como uma variação percentual das probabilidades relativas (*odds*) de aprovação.

Para complementar esta análise foi igualmente calculado o modelo base, correspondente ao valor do intercepto. Este valor representa a probabilidade prevista para um candidato hipotético cujas variáveis normalizadas assumem valor zero, funcionando como ponto de referência para interpretação dos restantes coeficientes.

```
# 1. Extract the intercept (Beta 0)
intercept = lr_model.intercept_[0]
base_odds = np.exp(intercept)
base_probability = base_odds / (1 + base_odds)

# 2. Extract coefficients and pair them with feature names
coefficients = lr_model.coef_[0]

# 3. Create an interpretation summary DataFrame
interpretation_df = pd.DataFrame({
    'Feature': feature_names,
    'Coefficient (Log-Odds)': coefficients,
    'Odds Ratio (e^coef)': np.exp(coefficients)
})

# 4. Calculate the percentage change in odds for intuitive reading
interpretation_df['Odds Change (%)'] = (interpretation_df['Odds Ratio (e^coef)'] - 1) * 100
```

6.1.1. Interpretação dos Coeficientes

A Tabela seguinte apresenta os coeficientes estimados pela Regressão Logística, respetivos *Odds Ratios* e variação percentual das *odds*.

Tabela 6 - Tabela de coeficientes e Odds Ratios da Regressão Logística

Feature	Coefficient (Log-Odds)	Odds Ratio (e^coef)	Odds Change (%)
ugpa	0.391383	1.479024	47.902431
race_black	-0.372178	0.689232	-31.076812
tier	0.305846	1.357773	35.777266
race_hisp	-0.226955	0.796957	-20.304343
fam_inc	0.182319	1.199996	19.999641
race_asian	-0.175552	0.838994	-16.100592
race_other	-0.134432	0.874212	-12.578779
male	0.074624	1.077479	7.747946

A análise dos coeficientes evidencia imediatamente que **UGPA** constitui a variável com maior influência positiva sobre a probabilidade de aprovação.

O coeficiente positivo associado a esta variável traduz-se num *Odds Ratio* de aproximadamente 1,48, indicando que um aumento unitário em **UGPA** aumenta em cerca de 48% as *odds* de aprovação, mantendo constantes as restantes variáveis.

Este resultado encontra-se perfeitamente alinhado com a expectativa inicial do projeto. Uma vez que **UGPA** representa desempenho académico anterior, seria esperado que constituísse o principal indicador de mérito utilizado pelo modelo.

Contudo, a análise revela igualmente que alguns atributos sensíveis apresentam coeficientes estatisticamente relevantes.

Destaca-se particularmente a variável `RACE_BLACK`, cujo coeficiente negativo corresponde a uma redução aproximada de 31% das *odds* de aprovação relativamente à categoria de referência.

Embora este resultado não permita, por si só, concluir a existência de discriminação algorítmica, constitui um primeiro indício de que o modelo aprendeu relações sistemáticas entre determinados grupos demográficos e a variável alvo.

Observações semelhantes verificam-se para outras categorias raciais e para o rendimento familiar, embora com magnitude inferior.

Esta análise confirma igualmente a motivação metodológica apresentada na seleção das variáveis. Apesar de `UGPA` permanecer como principal indicador de mérito académico, os atributos sensíveis continuam a exercer influência mensurável sobre as previsões, permitindo estudar precisamente a interação entre mérito individual e fatores demográficos.

6.2. Interpretação da *Decision Tree*

Ao contrário da Regressão Logística, cuja interpretação é efetuada através dos coeficientes do modelo, a *Decision Tree* apresenta uma estrutura hierárquica composta por sucessivas regras de decisão. Cada nó da árvore representa uma condição aplicada a uma variável específica, conduzindo progressivamente o candidato até um nó terminal (*leaf node*), onde é produzida a classificação final.

Esta característica torna a *Decision Tree* um modelo intrinsecamente interpretável, uma vez que todo o processo de decisão pode ser visualizado e percorrido desde a raiz da árvore até ao resultado final.




Figura 5 - Estrutura da *Decision Tree* treinada

A análise da árvore revela imediatamente um resultado particularmente relevante para os objetivos deste trabalho. A primeira divisão efetuada pelo modelo utiliza a variável `RACE_BLACK`, que constitui a raiz da árvore e, conseqüentemente, o primeiro critério utilizado para separar os candidatos.

Esta escolha resulta diretamente do algoritmo CART (*Classification and Regression Trees*), que seleciona, em cada nó, a variável que proporciona a maior redução da impureza segundo o critério de Gini. Assim, o facto de `RACE_BLACK` surgir na raiz da árvore significa que esta variável apresenta um elevado poder discriminativo relativamente à variável alvo no conjunto de dados utilizado.

É importante salientar que esta observação não implica, por si só, que o modelo esteja a introduzir discriminação. A árvore apenas aprende padrões estatísticos existentes nos dados de treino. Contudo, o facto de um atributo racial ser utilizado como primeiro critério de decisão constitui um forte indicador de que essa característica contém informação relevante para a previsão e merece uma análise mais aprofundada sob a perspetiva da *fairness*.

Após esta primeira divisão, a variável `UGPA` assume um papel dominante na maioria dos ramos da árvore. Diversas decisões subsequentes utilizam limiares sucessivos desta variável, como $UGPA \leq 2.15$, $UGPA \leq 2.55$ ou $UGPA \leq 2.65$, evidenciando que o desempenho académico continua a representar o principal indicador de mérito utilizado pelo modelo para diferenciar candidatos.

Além do desempenho académico, observa-se igualmente a utilização recorrente de variáveis como `TIER`, `FAM_INC`, `MALE` e das restantes categorias raciais. Estas variáveis surgem sobretudo em níveis intermédios da árvore, refinando a classificação de candidatos que apresentam desempenhos académicos semelhantes.

Este comportamento confirma que o processo de decisão não depende exclusivamente do mérito académico. Pelo contrário, a classificação final resulta da combinação de múltiplos atributos, incluindo características demográficas e socioeconómicas.

6.3. Explicabilidade Global

6.3.1. Resultados com SHAP

Embora a *Decision Tree* e a Regressão Linear permitam analisar de forma direta e simples a influência das features durante a classificação, esta representação torna-se rapidamente difícil de interpretar quando abordamos modelos mais complexos, como a *Random Forest*, que deixam de possuir uma estrutura facilmente analisável.

Por esta razão, recorreu-se à biblioteca SHAP (*SHapley Additive Explanations*), atualmente uma das abordagens mais utilizadas para interpretação de modelos de Machine Learning.

O SHAP baseia-se na teoria dos valores de Shapley, originalmente desenvolvida na teoria dos jogos cooperativos, atribuindo a cada variável uma contribuição quantitativa para a previsão produzida pelo modelo.

Ao contrário das métricas tradicionais de importância das variáveis, os valores SHAP permitem analisar simultaneamente a influência global de cada atributo e a sua contribuição individual para cada previsão.

Para o melhor modelo de *Random Forest* foi calculado um *TreeExplainer*, produzindo os respetivos valores SHAP.

```
# 1. Initialize the SHAP explainer specifically for Tree-based models (Random Forest)
shap_explainer = shap.TreeExplainer(rf_model)

# 2. Calculate SHAP values for the test dataset
shap_global_values = shap_explainer(X_test)
```

A análise global foi efetuada recorrendo ao gráfico *beeswarm*, que representa simultaneamente a importância média de cada variável e a distribuição dos seus efeitos sobre todas as observações do conjunto de teste.




Figura 6 - Gráfico de sumário global do SHAP

A análise do gráfico confirma que *UGPA* permanece como a variável mais influente na generalidade das previsões, resultado consistente com os coeficientes obtidos na Regressão Logística e com as primeiras divisões observadas na *Decision Tree*.

Contudo, verifica-se igualmente que atributos como *RACE_BLACK*, *FAM_INC* e *MALE* apresentam contribuições relevantes em diversos candidatos, demonstrando que o modelo não baseia exclusivamente as suas decisões no desempenho académico.

Outro aspeto importante revelado pelo SHAP consiste na possibilidade de observar simultaneamente o sentido da influência exercida por cada variável. Valores positivos nas variáveis raciais contribuem para diminuir a probabilidade de aprovação, enquanto valores positivos no mérito académico, rendimento familiar ou no sexo masculino deslocam a previsão no sentido da aprovação. Estas tendências confirmam exatamente os valores demonstrados pela Regressão Logística no capítulo 6.1.

Esta representação fornece uma visão global do comportamento do modelo, permitindo identificar quais os atributos mais utilizados durante o processo de decisão sem necessidade de analisar individualmente cada previsão.

6.3.2. Estudo com ELI5

Para complementar a análise de explicabilidade global obtida através do SHAP, recorreu-se igualmente ao ELI5, uma biblioteca que disponibiliza diferentes mecanismos de interpretação para modelos de *Machine Learning*. Neste trabalho foram utilizados dois métodos distintos: *Feature Weights*, que representa a importância estrutural das variáveis no modelo, e *Permutation Importance*, que avalia o impacto de cada variável no desempenho preditivo quando os seus valores são aleatoriamente permutados.

Tabela 7 - Pesos globais e importância de permutação atribuídos pelo ELI5

Variável	<i>Feature Weights</i>	<i>Permutation Importance</i>
UGPA	0.3463 ± 0.1081	0.0177 ± 0.0096
RACE_BLACK	0.2265 ± 0.1326	0.0167 ± 0.0118
TIER	0.1893 ± 0.0580	0.0086 ± 0.0066
FAM_INC	0.1057 ± 0.0471	0.0083 ± 0.0106
RACE_HISP	0.0548 ± 0.0302	0.0054 ± 0.0053
MALE	0.0299 ± 0.0248	0.0002 ± 0.0042
RACE_ASIAN	0.0271 ± 0.0183	-0.0002 ± 0.0031
RACE_OTHER	0.0205 ± 0.0116	-0.0024 ± 0.0019

Os resultados demonstram que UGPA constitui a variável com maior peso global na *Random Forest*, sendo responsável por aproximadamente um terço da importância total do modelo. Este resultado confirma que o desempenho académico anterior representa o principal fator utilizado pelo modelo na previsão do sucesso académico.

A segunda variável mais relevante é RACE_BLACK, seguida por TIER, evidenciando que tanto fatores demográficos como institucionais desempenham um papel importante na construção das árvores de decisão.

Embora `FAM_INC` apresente uma importância inferior, continua a contribuir de forma consistente para as previsões do modelo. Em contraste, as restantes variáveis (`RACE_HISP`, `RACE_ASIAN`, `RACE_OTHER` e `MALE`) apresentam pesos significativamente mais reduzidos, sugerindo uma influência global limitada.

De forma geral, esta hierarquia é coerente com a estrutura observada na Regressão Logística e na *Decision Tree*, onde `UGPA`, `RACE_BLACK` e `TIER` surgem repetidamente nos níveis superiores da árvore, participando num elevado número de decisões.

Complementarmente, foi aplicada a técnica de *Permutation Importance*, que estima a importância de cada variável através da degradação do desempenho do modelo após a permutação aleatória dos seus valores.

Ao contrário dos *Feature Weights*, a *Permutation Importance* mede a perda efetiva de desempenho do modelo quando determinada variável deixa de fornecer informação útil.

Os resultados mostram que `UGPA` continua a apresentar uma importância elevada, confirmando que o desempenho académico constitui um dos principais fatores utilizados pela *Random Forest*.

Contudo, observa-se que as diferenças entre as variáveis são significativamente menores, sendo a variável `MALE` aquela que provoca a maior redução do desempenho quando permutada, embora com um valor muito próximo do obtido para `UGPA`. Esta proximidade, associada aos desvios-padrão relativamente elevados, sugere que nenhuma variável individual é suficiente para explicar isoladamente o comportamento do modelo.

Também `RACE_BLACK` e `TIER` continuam a apresentar impacto positivo, embora inferior ao observado nos *Feature Weights*. Este comportamento é esperado, uma vez que a *Random Forest* distribui a informação entre múltiplas árvores e entre diferentes combinações de variáveis. Assim, mesmo quando uma variável importante é permutada, parte da informação pode ser recuperada através de atributos correlacionados ou de diferentes caminhos existentes nas árvores.

Por outro lado, as variáveis `RACE_HISP`, `RACE_ASIAN` e `RACE_OTHER` apresentam importâncias próximas de zero, indicando que a sua remoção praticamente não altera o desempenho global do modelo.

6.4. Explicabilidade Local

Embora a análise global permita compreender o comportamento médio do modelo, não explica as decisões tomadas para candidatos específicos.

Para esse efeito foram geradas explicações locais para registos da coleção de teste escolhidos para diferentes cenários.

Tabela 8 - Amostras alvo de estudo para explicabilidade local

	ugpa	tier	fam_inc	male	race_asian	race_black	race_hisp	race_other	Esperado	Previsto
1	3,1	5	3	0	0	0	0	0	1	1
2	3,1	5	3	0	0	1	0	0	1	0
3	3,7	3	4	0	0	1	0	0	1	0

O objetivo destes valores é perceber o que influenciou o erro na previsão de amostras específicas em que as variáveis associadas ao mérito académico são semelhantes, alterando apenas variáveis sensíveis.

A 3ª amostra a estudar teve inclusive um valor superior na variável dominante de mérito (UGPA) e ainda assim falhou a previsão.

6.4.1. Aplicação dos métodos SHAP, LIME e ELI5

Enquanto a análise global permite compreender o comportamento médio dos modelos, a explicabilidade local procura justificar decisões individuais, identificando o contributo específico de cada variável para uma determinada previsão.

Para esse efeito foram utilizadas três técnicas complementares: **SHAP**, **LIME** e **ELI5**. Embora recorram a metodologias distintas, todas têm como objetivo explicar por que razão um determinado candidato foi classificado como aprovado ou reprovado.

6.4.1.1. Resultados com SHAP

Além da explicabilidade global, é possível também obter explicabilidade local com o método SHAP, pois este permite justificar individualmente cada previsão através da decomposição da decisão em contribuições atribuídas a cada variável.




Figura 7 - Resultados da explicabilidade local com SHAP.

6.4.1.2. Resultados com LIME

O LIME aproxima localmente o comportamento do modelo recorrendo a uma regressão linear construída em torno da observação em análise. Para tal, são geradas múltiplas perturbações da instância original, permitindo identificar quais os atributos que mais influenciam a decisão naquela vizinhança específica.




Figura 8 - Resultados da explicabilidade local com LIME.

6.4.1.3. Validação das Explicações com ELI5

Como mecanismo adicional de validação das explicações obtidas, foi igualmente utilizada a biblioteca *eli5*, permitindo decompor localmente cada previsão nas contribuições individuais das variáveis.

O ELI5 apresenta diretamente a influência de cada atributo relativamente à classe prevista pelo modelo, incluindo o termo $\langle \text{BIAS} \rangle$, que corresponde ao intercepto da previsão e não deve ser confundido com o conceito de enviesamento algorítmico abordado neste trabalho.

Tabela 9 - Resultados da explicabilidade local com ELI5

	$\langle \text{BIAS} \rangle$	ugpa	tier	fam_inc	male	race_asian	race_black	race_hisp	race_other	Classe explicada
1	+0.499	-0,007	0,063	-0,007	0	0,009	0,055	0,015	0,006	1
2	+0.501	-0,077	-0,069	-0,023	0,013	-0,001	0,336	-0,005	-0,001	0
3	+0.501	-0,229	0,078	-0,057	0,01	-0,001	0,339	-0,005	-0,001	0

6.4.2. Comparação e discussão de Resultados

6.4.2.1. Caso #1 – Previsão correta (Aprovado)

O primeiro registo corresponde a um estudante corretamente classificado como aprovado, apresentando uma probabilidade de aproximadamente 63% para a classe positiva.

Tanto o LIME como o SHAP apresentam uma interpretação praticamente coincidente. Ambos identificam a ausência da variável `RACE_BLACK`, o valor elevado de `TIER` e um `UGPA` = **3.1** (intermédio) como os fatores que mais contribuem para aumentar a probabilidade de aprovação. Em sentido contrário, um rendimento familiar mais reduzido (`FAM_INC` = **3**) e o facto de o estudante ser do sexo feminino apresentam uma influência negativa, embora significativamente inferior.

Esta interpretação é coerente com a estrutura da *Decision Tree*, na qual a variável `RACE_BLACK` surge como primeiro critério de decisão, seguida por divisões relacionadas com `UGPA` e `TIER`, evidenciando que estes atributos condicionam grande parte das previsões do modelo.

No caso do ELI5, a explicação apresenta uma diferença conceptual relativamente aos restantes métodos. As contribuições são calculadas relativamente ao valor base da previsão e não representam diretamente o efeito da presença ou ausência de uma variável. Por esse motivo, surgem contribuições positivas para variáveis binárias com valor zero (como `RACE_BLACK` = **0**), situação que pode ser interpretada como a contribuição da regra seguida na árvore e não da presença da característica em si. Apesar desta diferença de representação, o conjunto de variáveis consideradas relevantes mantém-se consistente com o LIME e o SHAP.

6.4.2.2. Caso #2 – Falso Negativo

O segundo caso corresponde a um estudante que efetivamente obteve sucesso académico, mas que foi classificado pelo modelo como reprovado, com uma probabilidade aproximada de 67%.

Neste exemplo observa-se uma concordância muito elevada entre LIME e SHAP relativamente aos fatores determinantes da decisão.

Ambos identificam claramente que a variável `RACE_BLACK` = **1** constitui o principal fator responsável pela redução da probabilidade de aprovação. O SHAP atribui-lhe uma contribuição negativa de aproximadamente -0.27, enquanto o LIME evidencia igualmente esta variável como a mais penalizadora da previsão.

Em sentido contrário, o valor elevado de `TIER` e um `UGPA` de **3.1** contribuem positivamente para a previsão de sucesso, embora essa influência não seja suficiente para compensar o impacto associado à variável racial.

Este comportamento encontra-se igualmente alinhado com a estrutura da árvore de decisão, onde o primeiro nó separa imediatamente os indivíduos segundo a variável `RACE_BLACK`, condicionando todos os ramos seguintes.

O ELI5 apresenta novamente uma interpretação aparentemente inversa. Como a explicação é produzida relativamente à classe prevista (classe 0), a contribuição positiva observada para `RACE_BLACK` representa um aumento da probabilidade dessa classe e não da classe positiva. Assim, apesar da diferença visual, a conclusão prática coincide com SHAP e LIME: a presença desta variável foi determinante para que o modelo previsse insucesso.

6.4.2.3. Caso #3 – Falso Negativo

O terceiro registo representa igualmente um estudante aprovado que foi incorretamente classificado como reprovado.

Comparativamente ao caso anterior, este estudante apresenta um `UGPA` superior (3.7) e um rendimento familiar mais elevado (`FAM_INC` = 4), fatores que tanto o SHAP como o LIME identificam como importantes contributos para aumentar a probabilidade de sucesso.

Contudo, a variável `RACE_BLACK` = 1 continua a exercer a influência negativa dominante sobre a decisão do modelo.

No SHAP verifica-se uma contribuição negativa próxima de -0.30 para esta variável, praticamente anulando os efeitos positivos provenientes do melhor desempenho académico e do rendimento familiar.

O LIME evidencia exatamente a mesma tendência, identificando `RACE_BLACK` como o fator de maior impacto negativo, enquanto `UGPA`, `FAM_INC` e, em menor escala, `TIER`, contribuem favoravelmente para a classificação positiva.

Tal como nos casos anteriores, o ELI5 associa uma contribuição positiva elevada à variável `RACE_BLACK`. No entanto, esta contribuição refere-se novamente ao aumento da probabilidade da classe prevista (classe 0), sendo por isso compatível com as conclusões obtidas pelos restantes métodos.

6.5. Síntese dos Resultados de Explicabilidade

A análise conjunta dos três modelos evidencia um compromisso claro entre desempenho preditivo e interpretabilidade. A Regressão Logística apresentou o comportamento mais transparente, permitindo identificar diretamente o sentido e a magnitude da influência de cada variável. A *Decision Tree* complementou esta análise ao traduzir essas relações em regras de decisão facilmente compreensíveis, enquanto o *Random Forest*, apesar de alcançar o melhor desempenho preditivo, exigiu a utilização de técnicas de Inteligência Artificial Explicável (XAI) para tornar o seu processo de decisão interpretável.

Ao nível da explicabilidade global, observou-se uma elevada consistência entre todos os modelos. Independentemente da técnica utilizada (coeficientes da Regressão Logística, importância das variáveis da *Decision Tree*, SHAP e ELI5 no *Random Forest*), verificou-se que `UGPA`, `RACE_BLACK` e `TIER` constituem as variáveis com maior influência nas previsões, seguidas por `FAM_INC`, enquanto `MALE`, `RACE_ASIAN`, `RACE_HISP` e `RACE_OTHER`

apresentam contributos substancialmente inferiores. Esta convergência reforça a robustez das conclusões obtidas, demonstrando que diferentes abordagens de modelação identificam essencialmente os mesmos fatores determinantes.

A análise local confirmou igualmente uma forte concordância entre SHAP, LIME e ELI5 na identificação dos fatores determinantes para cada previsão individual. Embora existam diferenças na forma como cada método representa as contribuições das variáveis, todos evidenciam que alterações em atributos como `UGPA`, `RACE_BLACK`, `TIER` e `FAM_INC` podem modificar significativamente o resultado previsto. Esta capacidade de justificar previsões individuais constitui um elemento essencial para a validação técnica do modelo e para a sua auditabilidade.

De forma global, a combinação dos modelos interpretáveis com as técnicas de XAI permitiu demonstrar que o aumento da complexidade do modelo não implica necessariamente perda de transparência. Enquanto a Regressão Logística e a *Decision Tree* fornecem explicações intrínsecas do processo de decisão, o *Random Forest*, através de SHAP, LIME e ELI5, oferece explicações consistentes tanto ao nível global como local, permitindo compreender os fatores que conduzem às previsões individuais e validar que o seu comportamento permanece coerente com o conhecimento extraído pelos modelos interpretáveis.

Os resultados evidenciam igualmente que a utilização de atributos sensíveis, nomeadamente `RACE_BLACK`, exerce uma influência relevante nas decisões do modelo. Embora esta influência seja consistente entre os diferentes algoritmos e métodos de explicabilidade, a sua presença levanta questões relacionadas com equidade, potencial discriminação algorítmica e conformidade com os princípios da Inteligência Artificial Responsável. A identificação deste comportamento demonstra precisamente o valor das técnicas de explicabilidade, permitindo detetar fatores críticos que poderão justificar análises adicionais de enviesamento, justiça algorítmica e impacto ético.

Em síntese, o estudo demonstra que a combinação de modelos interpretáveis com técnicas de XAI permite conciliar desempenho preditivo, transparência e capacidade de auditoria. Para além de validar tecnicamente o comportamento do *Random Forest*, a explicabilidade revelou-se um instrumento fundamental para identificar fatores potencialmente sensíveis, suportando uma avaliação crítica da fiabilidade, da equidade e da conformidade do sistema com os princípios éticos e regulamentares que serão analisados nos capítulos seguintes.

7. Análise Ética

7.1. Introdução

O desenvolvimento de sistemas de Inteligência Artificial para apoio à decisão levanta um conjunto de desafios que ultrapassam o domínio estritamente técnico. Embora métricas como *Accuracy*, *Precision* ou *Recall* permitam avaliar o desempenho preditivo de um modelo, estas não são suficientes para determinar se a sua utilização é ética, justa ou socialmente aceitável. Um sistema pode apresentar um elevado nível de desempenho e, simultaneamente, produzir decisões discriminatórias caso aprenda padrões enviesados presentes nos dados utilizados durante o treino.

O presente trabalho teve precisamente como objetivo estudar este fenómeno. Ao invés de procurar eliminar o enviesamento existente no conjunto de dados, optou-se deliberadamente por utilizar um *dataset* amplamente conhecido na literatura por refletir desigualdades históricas associadas ao acesso à profissão jurídica. Esta decisão permitiu analisar de que forma diferentes algoritmos incorporam esses padrões e avaliar a capacidade das técnicas de interpretabilidade e de Inteligência Artificial Explicável em identificar a influência de atributos potencialmente sensíveis nas previsões produzidas.

Importa sublinhar que a inclusão de variáveis como raça e género neste estudo não constitui uma recomendação para a sua utilização em sistemas reais de apoio à decisão académica ou profissional. Pelo contrário, a sua presença foi deliberadamente mantida com uma finalidade exclusivamente científica e pedagógica: analisar de que forma atributos potencialmente sensíveis podem influenciar modelos de aprendizagem automática e avaliar se as técnicas de interpretabilidade e de XAI são capazes de detetar essa influência.

Num cenário real de avaliação de candidatos para percursos académicos, bolsas de estudo ou oportunidades profissionais, variáveis como raça e género dificilmente seriam consideradas critérios legítimos de decisão, uma vez que não representam indicadores diretos de mérito, competência ou potencial académico. A sua utilização poderia introduzir riscos significativos de discriminação direta ou indireta, motivo pelo qual muitos sistemas reais procuram excluir explicitamente este tipo de atributos ou aplicar mecanismos de mitigação de enviesamento.

Assim, os resultados obtidos neste trabalho não devem ser interpretados como uma validação da utilização destes atributos, mas sim como uma demonstração de como modelos de Inteligência Artificial podem aprender e reproduzir padrões presentes em dados históricos quando atributos sensíveis são disponibilizados durante o treino.

Neste contexto, a análise ética apresentada neste capítulo procura avaliar os principais riscos identificados ao longo do estudo, relacionando os resultados experimentais obtidos com os princípios internacionalmente reconhecidos da Inteligência Artificial Responsável, nomeadamente a justiça algorítmica (*Fairness*), a transparência, a explicabilidade, a responsabilidade e a supervisão humana.

7.2. Identificação de atributos sensíveis

Uma das primeiras etapas de qualquer avaliação ética consiste na identificação dos atributos potencialmente sensíveis presentes no conjunto de dados. No caso do *dataset* utilizado neste trabalho foram selecionadas variáveis que, além da sua relevância preditiva, permitiam estudar explicitamente o fenômeno do enviesamento algorítmico.

As variáveis `RACE_BLACK`, `RACE_ASIAN`, `RACE_HISP` e `RACE_OTHER` representam categorias raciais dos candidatos e constituem atributos tradicionalmente considerados sensíveis, uma vez que podem dar origem a discriminação direta ou indireta. De igual forma, a variável `MALE` representa o género do estudante, enquanto `FAM_INC` constitui um indicador indireto da condição socioeconómica do agregado familiar.

A seleção destas variáveis foi intencional e encontra-se alinhada com os objetivos do trabalho. Ao contrário de uma abordagem orientada exclusivamente para maximizar o desempenho preditivo, optou-se por preservar atributos potencialmente problemáticos precisamente para analisar de que forma estes influenciam os diferentes modelos de aprendizagem automática e para avaliar se as técnicas de interpretabilidade seriam capazes de evidenciar esse comportamento.

Os resultados obtidos confirmam essa influência. Tanto os modelos interpretáveis como a *Random Forest* identificaram `RACE_BLACK` entre as variáveis mais relevantes das previsões, sendo igualmente evidenciado um contributo consistente das variáveis `TIER` e `FAM_INC`. Embora `UGPA` permaneça como o principal fator académico associado ao sucesso, verifica-se que características demográficas continuam a exercer um impacto significativo nas decisões produzidas pelos modelos.

Esta constatação não permite concluir que exista discriminação deliberada por parte dos algoritmos. Pelo contrário, evidencia que os modelos aprenderam padrões estatísticos presentes no conjunto de dados, refletindo desigualdades históricas existentes no contexto em que esses dados foram recolhidos.

7.3. Fairness observada nos modelos

A comparação entre os três algoritmos revelou que o aumento da complexidade do modelo conduz a melhorias progressivas nas métricas tradicionais de desempenho, verificando-se um aumento da *Accuracy* desde a Regressão Logística até à *Random Forest*. Contudo, esta evolução não foi acompanhada por uma redução da influência dos atributos sensíveis.

Pelo contrário, a análise de interpretabilidade demonstrou que variáveis relacionadas com a raça permaneceram entre os principais fatores considerados pelos três modelos. A Regressão Logística evidenciou coeficientes negativos associados à variável `RACE_BLACK`, a *Decision Tree* utilizou esta variável como primeiro critério de divisão da árvore e a *Random Forest* confirmou, através das análises SHAP, LIME e ELI5, que esta variável influencia significativamente tanto as explicações globais como diversas previsões individuais.

Este comportamento constitui uma conclusão particularmente relevante do estudo. O enviesamento observado não resulta da escolha do algoritmo utilizado, mas sim da informação presente no conjunto de dados de treino. Embora modelos mais complexos sejam capazes de capturar relações não lineares e produzir previsões mais precisas, continuam a reproduzir padrões históricos existentes nos dados quando estes não são previamente mitigados.

Desta forma, verifica-se que o aumento da capacidade preditiva não implica, necessariamente, uma melhoria da justiça algorítmica. A obtenção de melhores métricas de desempenho não elimina o risco de decisões potencialmente discriminatórias, reforçando a necessidade de avaliar simultaneamente critérios de precisão e critérios de equidade durante o desenvolvimento de sistemas de Inteligência Artificial.

7.4. Principais riscos éticos identificados

A análise desenvolvida ao longo deste trabalho permitiu identificar diversos riscos éticos que poderiam surgir caso um sistema com características semelhantes fosse utilizado num contexto real de apoio à decisão.

O primeiro risco prende-se com a possibilidade de discriminação indireta. Embora o objetivo do modelo seja prever a probabilidade de sucesso académico, a influência significativa da variável `RACE_BLACK` demonstra que características demográficas podem afetar as previsões produzidas, conduzindo potencialmente a decisões menos favoráveis para determinados grupos populacionais.

Um segundo risco consiste na perpetuação de desigualdades históricas. Os algoritmos de aprendizagem automática não distinguem relações causais de simples correlações estatísticas, limitam-se a reproduzir os padrões existentes nos dados. Consequentemente, se o conjunto de treino refletir desigualdades acumuladas ao longo do tempo, essas desigualdades tenderão igualmente a ser reproduzidas pelo modelo.

A utilização de modelos complexos introduz ainda riscos relacionados com a opacidade das decisões automatizadas. Sem a aplicação das técnicas de explicabilidade utilizadas neste trabalho, seria difícil compreender os motivos que conduziram a determinadas previsões individuais, reduzindo significativamente a confiança dos utilizadores e dificultando a deteção de potenciais comportamentos discriminatórios.

Finalmente, importa considerar o impacto social decorrente da utilização de sistemas desta natureza em processos de elevada relevância, como a seleção de candidatos para programas académicos ou profissionais. Nestes cenários, decisões incorretas ou enviesadas podem produzir consequências significativas para os indivíduos afetados, justificando a necessidade de mecanismos robustos de supervisão humana e auditoria contínua.

7.5. Estratégias de mitigação

Embora a identificação do enviesamento constitua um dos principais resultados deste estudo, não foram aplicadas técnicas de mitigação durante o desenvolvimento experimental.

Caso o sistema viesse a ser desenvolvido para utilização operacional, seria recomendável incorporar mecanismos adicionais de mitigação de enviesamento ao longo do ciclo de vida do modelo. Entre as estratégias mais utilizadas encontram-se o reequilíbrio estatístico dos dados de treino, técnicas de *reweighing*, algoritmos de *adversarial debiasing*, métodos baseados em restrições de *fairness* (como *Equalized Odds* ou *Demographic Parity*) e processos de monitorização contínua após a entrada em produção.

Independentemente da técnica adotada, qualquer intervenção desta natureza deverá procurar equilibrar dois objetivos frequentemente contraditórios: a maximização do desempenho preditivo e a redução do impacto discriminatório sobre grupos protegidos. A escolha da solução mais adequada dependerá sempre do contexto de aplicação, dos requisitos legais e do nível de risco associado ao sistema.

8. Conformidade com o AI Act

8.1. Enquadramento

Conforme referido anteriormente, o conjunto de dados utilizado neste trabalho foi recolhido nos Estados Unidos e no Canadá, não estando, por isso, sujeito ao enquadramento jurídico europeu. Consequentemente, a presente análise assume um carácter hipotético, avaliando de que forma o sistema desenvolvido teria de ser adaptado caso fosse implementado na União Europeia.

O Regulamento (UE) 2024/1689, designado por *Artificial Intelligence Act* (AI Act), estabelece o primeiro quadro jurídico abrangente para sistemas de Inteligência Artificial, adotando uma abordagem baseada no risco. Em vez de regular todas as aplicações de IA da mesma forma, o regulamento classifica os sistemas em diferentes níveis de risco, impondo requisitos proporcionais ao potencial impacto que podem exercer sobre os direitos fundamentais, a segurança e os interesses dos cidadãos.

Neste contexto, sistemas utilizados para apoiar decisões relacionadas com educação, formação ou acesso a oportunidades profissionais podem enquadrar-se na categoria de *High-Risk AI Systems*, ficando sujeitos a requisitos rigorosos de governação, transparência, supervisão humana e gestão contínua do risco.

Embora o sistema desenvolvido neste trabalho constitua apenas um protótipo académico, a sua natureza torna-o particularmente interessante para avaliar o grau de conformidade que seria exigido caso viesse a ser utilizado em contexto operacional.

8.2. Classificação do sistema segundo o AI Act

Apesar de o caso de estudo utilizar um conjunto de dados histórico para fins exclusivamente académicos, um sistema com funcionalidade equivalente poderia ser utilizado para apoiar decisões relacionadas com a admissão a programas de formação, concessão de bolsas de estudo ou seleção de candidatos para percursos profissionais. Nestes cenários, as previsões produzidas pelo sistema podem influenciar oportunidades futuras dos indivíduos, enquadrando-se potencialmente nas situações previstas pelo Anexo III do AI Act, relativo aos sistemas de IA de alto risco aplicados ao domínio da educação e formação profissional.

Neste cenário hipotético, o sistema deveria ser considerado um *High-Risk AI System*, ficando sujeito ao conjunto de requisitos previstos no Capítulo III do Regulamento.

Importa salientar, contudo, que a classificação como sistema de alto risco não implica que a utilização da Inteligência Artificial seja proibida. Pelo contrário, significa apenas que o sistema deve cumprir requisitos técnicos, organizacionais e documentais adicionais, destinados a garantir a proteção dos direitos fundamentais e a fiabilidade das decisões produzidas.

8.3. Avaliação dos requisitos do AI Act

O AI Act estabelece um conjunto de obrigações específicas para sistemas classificados como de alto risco. A Tabela 10 sintetiza a avaliação do sistema desenvolvido face aos principais requisitos do regulamento.

Tabela 10 - Análise de cumprimento dos requisitos do AI Act

Requisito	Avaliação	Justificação
Sistema de gestão do risco	Parcial	Foi realizada avaliação experimental do desempenho e do enviesamento, mas não existe um processo formal e contínuo de gestão do risco ao longo do ciclo de vida do sistema.
Governança e qualidade dos dados	Parcial	O <i>dataset</i> foi previamente analisado e documentado, sendo reconhecido na literatura pelos enviesamentos que contém. Contudo, não foram aplicadas estratégias de mitigação de bias, uma vez que esse constituía precisamente o objeto de estudo.
Documentação técnica	Cumpre	O desenvolvimento do sistema, metodologia, parâmetros experimentais, resultados e limitações encontram-se integralmente documentados neste relatório.
Registo e rastreabilidade	Parcial	Foram preservados os parâmetros dos modelos, resultados experimentais e <i>logs</i> de execução. No entanto, não existe um mecanismo contínuo de <i>logging</i> e monitorização em ambiente de produção.
Transparência e explicabilidade	Cumpre	Foram utilizadas técnicas de interpretabilidade (Regressão Logística e <i>Decision Tree</i>) e de XAI (SHAP, LIME e ELI5), permitindo explicar tanto o comportamento global como previsões individuais do modelo.
Supervisão humana	Cumpre	O sistema foi concebido exclusivamente como ferramenta de apoio à decisão, não substituindo a intervenção humana em qualquer etapa do processo.
Robustez e desempenho	Cumpre	Foram utilizados procedimentos de validação cruzada, <i>Grid Search</i> e comparação entre diferentes algoritmos, assegurando uma avaliação sistemática do desempenho dos modelos.

A análise demonstra que o sistema satisfaz vários dos requisitos técnicos previstos no AI Act, particularmente ao nível da documentação, da transparência e da robustez experimental. Contudo, persistem algumas lacunas relacionadas com a operacionalização do sistema em contexto real, nomeadamente ao nível da gestão contínua do risco e da monitorização pós-implementação.

Outra nota importante referir, no âmbito do requisito de “Governança e qualidade dos dados”, a utilização de atributos sensíveis como raça ou género num sistema operacional de apoio à decisão exigiria uma justificação particularmente rigorosa e poderia levantar sérias questões de conformidade com os princípios de minimização de dados, não discriminação e proteção dos direitos fundamentais promovidos pelo AI Act.

8.4. Transparência e explicabilidade como requisitos regulamentares

Um dos aspetos mais inovadores do AI Act consiste na valorização da transparência e da explicabilidade como elementos essenciais para a utilização responsável da Inteligência Artificial.

Ao longo deste trabalho, foram aplicadas diversas técnicas de interpretabilidade e de XAI precisamente com esse objetivo. A Regressão Logística permitiu compreender a influência global das variáveis através dos respetivos coeficientes, enquanto a *Decision Tree* tornou explícitas as regras de decisão utilizadas pelo modelo. No caso da *Random Forest*, as técnicas SHAP, LIME e ELI5 permitiram explicar tanto a importância global das variáveis como os fatores responsáveis por previsões individuais.

Os resultados obtidos demonstraram que estas técnicas são capazes de revelar não apenas os fatores que contribuem para uma determinada previsão, mas também de identificar a influência exercida por atributos potencialmente sensíveis, como a variável `RACE_BLACK`. Esta capacidade constitui um elemento fundamental para a auditoria dos modelos, permitindo avaliar a existência de potenciais enviesamentos e justificar decisões perante utilizadores ou entidades reguladoras.

Assim, embora a utilização destas técnicas não garanta, por si só, a conformidade regulamentar, representa um contributo significativo para o cumprimento dos princípios de transparência, auditabilidade e prestação de contas previstos no AI Act.

8.5. Lacunas e adaptações necessárias

Caso o sistema desenvolvido viesse a ser implementado num contexto produtivo sujeito ao AI Act, seria necessário complementar o trabalho realizado com um conjunto de mecanismos adicionais de natureza técnica e organizacional:

- Estabelecer um processo formal de gestão contínua do risco, incluindo procedimentos periódicos de identificação, avaliação e mitigação de potenciais impactos sobre os direitos fundamentais.
- Implementar mecanismos de monitorização pós-implementação, permitindo acompanhar a evolução do desempenho do modelo, detetar deriva dos dados (*data drift*), monitorizar indicadores de *fairness* e desencadear ações corretivas sempre que fossem identificados comportamentos anómalos.
- Reforçar a governação dos dados através da documentação completa da proveniência dos dados, da validação da respetiva qualidade e da implementação de processos de revisão periódica destinados a reduzir a influência de enviesamentos históricos.
- Assegurar mecanismos de supervisão humana efetiva, garantindo que as previsões produzidas pela Inteligência Artificial constituem apenas um elemento de apoio ao decisor, nunca substituindo integralmente o julgamento humano em decisões com impacto significativo sobre os indivíduos.

9. Conformidade com o GDPR

9.1. Enquadramento

À semelhança da análise efetuada relativamente ao AI Act, a avaliação apresentada neste capítulo assume um carácter meramente hipotético. O conjunto de dados utilizado neste trabalho corresponde ao LSAC Bar Passage Dataset, recolhido nos Estados Unidos e no Canadá, não estando sujeito ao enquadramento jurídico do Regulamento (UE) 2016/679, conhecido como Regulamento Geral sobre a Proteção de Dados (GDPR).

Ainda assim, dada a crescente utilização de sistemas de Inteligência Artificial em processos de apoio à decisão, torna-se pertinente analisar de que forma um sistema com características semelhantes teria de ser concebido caso fosse implementado na União Europeia.

O RGPD estabelece um conjunto de princípios destinados a garantir que o tratamento de dados pessoais ocorre de forma lícita, transparente e proporcional, assegurando simultaneamente a proteção dos direitos fundamentais dos titulares dos dados. Estes princípios assumem particular relevância quando os sistemas de Inteligência Artificial recorrem a informação pessoal para produzir previsões ou recomendações suscetíveis de influenciar decisões com impacto significativo sobre os indivíduos.

No contexto deste trabalho, a utilização de atributos académicos, demográficos e socioeconómicos torna particularmente relevante a análise dos princípios da licitude, minimização de dados, transparência e decisões automatizadas previstos no regulamento.

9.2. Dados pessoais e categorias especiais

O conjunto de dados utilizado contém diversas variáveis que, num contexto real, seriam consideradas dados pessoais na aceção do artigo 4.º do GDPR.

Entre estas incluem-se variáveis académicas, como `UGPA`, variáveis socioeconómicas, como `FAM_INC`, e características demográficas, nomeadamente o género e a raça dos estudantes.

Particular destaque merece a variável da raça, representada através das categorias `RACE_BLACK`, `RACE_ASIAN`, `RACE_HISP` e `RACE_OTHER`. Nos termos do artigo 9.º do GDPR, a origem racial ou étnica constitui uma categoria especial de dados pessoais, cujo tratamento é, por regra, proibido, salvo nas exceções expressamente previstas no regulamento.

Embora neste trabalho estas variáveis tenham sido mantidas por motivos exclusivamente académicos, permitindo estudar a existência de enviesamentos algorítmicos e avaliar a eficácia das técnicas de explicabilidade, a sua utilização num sistema operacional de apoio à decisão exigiria uma fundamentação jurídica particularmente robusta.

Importa igualmente referir que atributos como raça e género dificilmente constituiriam critérios legítimos para apoiar decisões relacionadas com o percurso

académico ou profissional dos candidatos. Do ponto de vista do mérito académico, estas características não representam indicadores objetivos de competência ou desempenho, pelo que a sua utilização poderia originar discriminação direta ou indireta. Assim, num cenário real, seria expectável que estas variáveis fossem excluídas do processo de modelação ou substituídas por mecanismos de mitigação de enviesamento que reduzissem a sua influência nas decisões produzidas.

9.3. Princípios do RGPD aplicáveis ao sistema

A eventual implementação deste sistema na União Europeia exigiria o cumprimento dos princípios fundamentais estabelecidos no artigo 5.º do RGPD.

O princípio da licitude, lealdade e transparência implicaria que os titulares dos dados fossem devidamente informados sobre a finalidade do tratamento, o funcionamento geral do sistema e a forma como os seus dados influenciam as previsões produzidas.

O princípio da limitação da finalidade exigiria que os dados recolhidos fossem utilizados exclusivamente para o propósito inicialmente definido, não podendo ser posteriormente reutilizados para finalidades incompatíveis.

Relativamente ao princípio da minimização dos dados, os resultados obtidos ao longo deste trabalho assumem particular importância. Apesar de variáveis como raça e género demonstrarem capacidade preditiva, tal facto não significa que devam integrar um sistema operacional. Pelo contrário, o RGPD determina que apenas sejam tratados os dados estritamente necessários para atingir a finalidade pretendida. Considerando que estas variáveis não constituem indicadores diretos de mérito académico, a sua inclusão dificilmente poderia ser justificada numa aplicação real.

O princípio da exatidão implicaria igualmente a necessidade de assegurar que os dados utilizados permanecem atualizados e representam corretamente a realidade dos indivíduos, reduzindo o risco de decisões incorretas baseadas em informação desatualizada.

Finalmente, o princípio da responsabilização (*Accountability*) exigiria que a entidade responsável pelo sistema fosse capaz de demonstrar, de forma documentada, o cumprimento de todos estes requisitos ao longo do ciclo de vida do modelo.

9.4. Transparência e direito à explicação

Um dos aspetos mais relevantes do RGPD para sistemas de Inteligência Artificial relaciona-se com a transparência das decisões produzidas.

Embora o regulamento não imponha explicitamente a utilização de técnicas de Inteligência Artificial Explicável, estabelece que os titulares dos dados devem receber informação significativa sobre a lógica subjacente aos tratamentos automatizados, especialmente quando estes produzem efeitos relevantes sobre os indivíduos.

Neste contexto, as técnicas de interpretabilidade implementadas ao longo deste trabalho constituem um contributo importante para satisfazer este requisito.

9.5. Decisões automatizadas e supervisão humana

O artigo 22.º do GPDR reconhece aos titulares dos dados o direito de não ficarem sujeitos a decisões baseadas exclusivamente em tratamento automatizado quando estas produzam efeitos jurídicos ou impactos significativamente relevantes na sua esfera pessoal.

Embora o sistema desenvolvido neste trabalho tenha sido concebido apenas para fins experimentais, um modelo semelhante poderia, num cenário real, influenciar decisões relacionadas com admissões académicas, bolsas de estudo ou oportunidades profissionais.

Os resultados obtidos ao longo deste estudo reforçam esta necessidade. A influência observada de variáveis sensíveis, como `RACE_BLACK`, demonstra que decisões automatizadas podem reproduzir padrões históricos existentes nos dados, justificando a existência de mecanismos de revisão humana capazes de identificar e corrigir potenciais situações de discriminação.

Nessas circunstâncias, a utilização do sistema deveria limitar-se a apoiar o decisor humano, funcionando como um mecanismo auxiliar de análise e nunca como substituto integral da avaliação humana.

9.6. Avaliação global da conformidade

A Tabela 11 apresenta uma síntese da avaliação do sistema desenvolvido face aos principais requisitos do GPDR.

Tabela 11 - Análise de cumprimento dos requisitos do GPDR

Requisito	Avaliação	Justificação
Licitude do tratamento	Parcial	O tratamento seria admissível apenas mediante uma base jurídica adequada, inexistente no contexto experimental.
Minimização dos dados	Não cumpre	O modelo utiliza atributos sensíveis (raça e género) que dificilmente seriam necessários numa aplicação operacional.
Transparência	Cumpre	As técnicas de interpretabilidade e XAI permitem justificar o funcionamento global e local dos modelos.
Direito à informação	Parcial	A documentação técnica é extensa, mas não foram concebidos mecanismos específicos de comunicação dirigidos aos titulares dos dados.
Decisões automatizadas	Parcial	O sistema foi concebido como apoio à decisão, mas não incorpora mecanismos formais de intervenção humana em contexto operacional.
Accountability	Parcial	Existe documentação detalhada do desenvolvimento experimental, embora não exista um sistema formal de auditoria contínua.

De forma global, verifica-se que o sistema desenvolvido demonstra um elevado nível de transparência e auditabilidade, beneficiando significativamente da utilização das técnicas de Inteligência Artificial Explicável implementadas ao longo do trabalho. Contudo, a utilização de atributos sensíveis como raça e género representa o principal obstáculo à conformidade integral com o GPDR, exigindo uma revisão profunda da seleção de variáveis caso o sistema fosse destinado à utilização real.

10. Conclusão

O presente trabalho teve como principal objetivo analisar o impacto do enviesamento em modelos de Aprendizagem Automática aplicados à previsão do sucesso académico, recorrendo a um conjunto de dados reconhecido na literatura pela presença de padrões históricos potencialmente discriminatórios. Ao contrário de uma abordagem orientada exclusivamente para a maximização do desempenho preditivo, optou-se por preservar atributos sensíveis durante o processo de modelação, permitindo estudar de que forma estes influenciam diferentes algoritmos e avaliar a eficácia das técnicas de interpretabilidade e de Inteligência Artificial Explicável na identificação desses comportamentos.

Os resultados obtidos demonstraram que o aumento da complexidade dos modelos conduziu a melhorias progressivas nas métricas tradicionais de desempenho, tendo a *Random Forest* apresentado a melhor capacidade preditiva. Contudo, verificou-se igualmente que essa melhoria não eliminou a influência exercida por atributos sensíveis, particularmente pela variável `RACE_BLACK`, cuja relevância foi confirmada tanto pelos modelos interpretáveis como pelas diferentes técnicas de XAI aplicadas. Esta constatação evidencia que o enviesamento observado resulta essencialmente dos padrões presentes nos dados e não da escolha do algoritmo em si.

A utilização combinada da Regressão Logística, da *Decision Tree* e das técnicas SHAP, LIME e ELI5 revelou-se fundamental para compreender o comportamento dos modelos, permitindo justificar previsões individuais, interpretar a importância global das variáveis e identificar fatores potencialmente problemáticos do ponto de vista ético. A convergência observada entre diferentes métodos de explicabilidade reforçou a confiança na consistência das conclusões obtidas e demonstrou o papel essencial da XAI na auditoria de sistemas de Inteligência Artificial.

A análise ética e regulamentar permitiu ainda concluir que, embora o sistema desenvolvido apresente um elevado nível de transparência e auditabilidade, a utilização de atributos como raça e género apenas se justifica no contexto experimental deste estudo. Num cenário real de apoio à decisão, estes atributos dificilmente seriam compatíveis com os princípios da Inteligência Artificial Responsável, do AI Act e do Regulamento Geral sobre a Proteção de Dados, sendo necessária a sua exclusão ou a implementação de mecanismos específicos de mitigação de enviesamento, supervisão humana e monitorização contínua.

Em síntese, este trabalho demonstra que o desenvolvimento de sistemas de Inteligência Artificial não deve ser avaliado apenas pela sua capacidade preditiva. A confiança nestes sistemas depende igualmente da sua transparência, da possibilidade de explicar as decisões produzidas, da identificação de potenciais enviesamentos e da sua conformidade com princípios éticos e regulamentares. Neste contexto, a explicabilidade assume um papel central, não apenas como ferramenta técnica de interpretação dos modelos, mas também como um elemento essencial para promover uma Inteligência Artificial mais responsável, justa e digna de confiança.